Université Ibn Zohr | Faculté des Sciences Appliquées de Ouarzazate
Master Intelligence Artificielle et Applications (IAA)

Module : Optimisation numerique

Sélection de variables pour la classification par Algorithme Génétique : comparaison avec PSO binaire et une référence simple

Réalisé par :

Hamza Oukhacha et **EL-JANDOUZ HASSANE**

Encadré par : Pr. Aissam Hadri

Année universitaire 2026–2027

Remerciements

Nous tenons à exprimer nos sincères remerciements à notre professeur, Issam Hadri, pour son encadrement, ses explications claires et ses conseils sur la rédaction d'un rapport dans le respect des règles de la recherche scientifique. Son soutien nous a permis de surmonter les difficultés techniques et de mener ce travail à bien, de la meilleure manière possible.

Résumé

La sélection de variables vise à retenir, parmi les variables d'un jeu de données, un sous-ensemble réduit qui préserve ou améliore la performance d'un classifieur. Ce problème combinatoire est souvent traité par des métaheuristiques coûteuses, dont l'apport réel face à des méthodes simples est rarement mesuré à budget égal. Ce travail compare un algorithme génétique (AG) et une optimisation par essaim particulaire binaire (BPSO) à deux références simples : l'utilisation de toutes les variables et un filtre univarié (*objectif*). Les deux métaheuristiques disposent du même budget de 620 évaluations ; toutes les méthodes sont évaluées avec un classifieur k-NN sur trois jeux de données de référence, selon un protocole de 10 répétitions où la sélection n'utilise jamais l'ensemble de test, et les différences sont testées par le test de Wilcoxon. Sur Sonar (60 variables), l'AG atteint 81,3 % de précision avec 25,9 variables en moyenne, le BPSO 79,4 % avec 28,5 variables et le filtre 77,6 % avec 29,4 variables, contre 80,0 % avec toutes les variables ; la sélection par AG est 44 fois plus lente que le filtre. Dans nos conditions expérimentales, l'AG n'améliore significativement la précision du filtre sur aucun jeu de données, alors que sa sélection est 44 à 57 fois plus lente : du point de vue de la précision, son coût de calcul n'est pas justifié.

Mots-clés : sélection de variables ; approche wrapper ; algorithme génétique ; optimisation par essaim particulaire binaire ; classification ; k plus proches voisins.

Abstract

Feature selection aims to retain a small subset of the original variables that preserves or improves classifier performance. This combinatorial problem is often addressed with costly metaheuristics, whose actual benefit over simple methods is rarely measured under an equal budget. This work compares a genetic algorithm (GA) and binary particle swarm optimization (BPSO) with two simple baselines : using all features and a univariate filter (ANOVA F). Both metaheuristics receive the same budget of 620 fitness evaluations. All methods are evaluated with a k-NN classifier on three benchmark datasets, using 10 repetitions in which the test set is never used for selection ; differences are assessed with the Wilcoxon signed-rank test. On Sonar (60 features), the GA reaches 81.3% accuracy with 25.9 features on average, BPSO 79.4% with 28.5 features and the filter 77.6% with 29.4 features, versus 80.0% with all features; GA selection is 44 times slower than the filter. Under our experimental conditions, the GA does not significantly improve on the filter's accuracy on any dataset, while being 44 to 57 times slower: in terms of accuracy, its computational cost is not justified.

Keywords : feature selection ; wrapper approach ; genetic algorithm ; binary particle swarm optimization ; classification ; k-nearest neighbors.

Table des matières

Remerciements i

Résumé ii

Abstract iii

Liste des abréviations et symboles viii

Introduction générale 1

1 État de l'art 3
- 1.1 Introduction du chapitre . . . 3
- 1.2 Méthodologie de la recherche documentaire . . . 3
  - 1.2.1 De la question de recherche aux mots-clés . . . 3
  - 1.2.2 Requête et bases interrogées . . . 3
  - 1.2.3 Critères de sélection et organisation . . . 4
- 1.3 Familles de méthodes de sélection de variables . . . 4
- 1.4 Algorithmes génétiques pour la sélection de variables . . . 4
- 1.5 PSO et sa version binaire . . . 5
- 1.6 Synthèse critique et positionnement . . . 5
- 1.7 Conclusion du chapitre . . . 6

2 Matériels et méthodologie 7
- 2.1 Introduction du chapitre . . . 7
- 2.2 Jeux de données . . . 7
- 2.3 Formulation du problème . . . 7
- 2.4 Méthodes comparées . . . 8
  - 2.4.1 Références simples . . . 8
  - 2.4.2 Algorithme génétique (AG) . . . 8
  - 2.4.3 PSO binaire (BPSO) . . . 8
  - 2.4.4 Équité de la comparaison . . . 9
- 2.5 Protocole expérimental . . . 9
- 2.6 Critères d'évaluation et analyse statistique . . . 9
- 2.7 Environnement logiciel et reproductibilité . . . 10
- 2.8 Conclusion du chapitre . . . 10

3 Résultats et discussion 11
- 3.1 Introduction du chapitre . . . 11
- 3.2 Précision de classification . . . 11
- 3.3 Nombre de variables sélectionnées . . . 12
- 3.4 Temps de calcul . . . 12
- 3.5 Significativité statistique . . . 12

3.6 Convergence des métaheuristiques 13
3.7 Discussion 13
3.7.1 Vérification des hypothèses 13
3.7.2 Interprétation 14
3.7.3 Comparaison avec la littérature 14
3.7.4 Limites 14
3.8 Conclusion du chapitre 15

Conclusion générale et perspectives **16**

Références **17**

A Code source et reproductibilité **19**

B Fiches de lecture **20**

Table des figures

3.1 Distribution de la précision sur le test sur les 10 répétitions. 11
3.2 Convergence : meilleure fitness moyenne par itération (± écart-type, 10 répétitions). 13

Liste des tableaux

1.1 Concepts de la question de recherche et mots-clés associés. 3
1.2 Résultats de la recherche documentaire. 4
1.3 Comparaison des familles de méthodes de sélection de variables. 4
1.4 Synthèse de travaux représentatifs. 5

2.1 Jeux de données utilisés (source : UCI Machine Learning Repository [16]). 7
2.2 Paramètres des métaheuristiques. 9

3.1 Précision sur le test en % (moyenne ± écart-type sur $R = 10$ répétitions). Meilleure moyenne en gras. 11
3.2 Nombre de variables sélectionnées $|S|$ (moyenne ± écart-type). Plus petite moyenne en gras (hors Toutes). 12
3.3 Temps moyen de sélection par exécution (secondes) et rapport au temps du filtre. 12
3.4 Test de Wilcoxon apparié, bilatéral (valeurs p ; en gras si $p < 0{,}05$). 12

B.1 Fiches de lecture des principaux articles. 20

Liste des abréviations et symboles

AG	Algorithme génétique
PSO	Optimisation par essaim particulaire (*Particle Swarm Optimization*)
BPSO	PSO binaire (*Binary PSO*)
k-NN	k plus proches voisins (*k-Nearest Neighbors*)
CV	Validation croisée (*Cross-Validation*)
ANOVA	Analyse de la variance
N	Nombre total de variables d'un jeu de données
n	Nombre d'exemples d'un jeu de données
S, $\|S\|$	Sous-ensemble de variables sélectionnées, et sa taille
f	Fonction objectif (fitness), à minimiser
α	Poids de l'erreur de classification dans f
P, T	Taille de la population (ou de l'essaim) et nombre d'itérations
R	Nombre de répétitions indépendantes de l'expérience

Introduction générale

Contexte

En apprentissage automatique, les jeux de données contiennent de plus en plus de variables (*features*). Dans certains domaines, comme l'analyse de l'expression des gènes ou la classification de textes, une seule observation peut être décrite par des dizaines de milliers de variables [1]. Or toutes ces variables ne sont pas utiles : beaucoup d'entre elles sont non pertinentes ou redondantes [2]. Leur présence expose au *fléau de la dimension* et pose trois problèmes [1] :

1. elle ralentit l'entraînement et l'utilisation des modèles de classification ;
2. elle augmente le risque de surapprentissage (*overfitting*) : le modèle apprend le bruit des données au lieu des régularités utiles ;
3. elle rend le modèle plus difficile à interpréter.

Pour y remédier, on utilise la *sélection de variables*, qui consiste à retenir uniquement un sous-ensemble de variables pertinentes, sans les transformer. Parmi les approches proposées, les algorithmes d'optimisation bio-inspirés, comme les algorithmes génétiques (AG) [3], [4] et l'optimisation par essaim particulaire binaire (BPSO) [5], sont largement étudiés [2], [6], [7]. Ces méthodes évaluent chaque sous-ensemble candidat en entraînant le classifieur lui-même à chaque étape de la recherche : c'est l'approche dite *wrapper* [8].

Problématique

Trouver le meilleur sous-ensemble de variables est un problème combinatoire classé NP-difficile [2], [7]. Pour N variables, il existe 2^N sous-ensembles possibles [8] : pour le jeu Sonar ($N = 60$), cela représente environ $1{,}15 \times 10^{18}$ combinaisons. Même à raison de 10 ms par évaluation, une recherche exhaustive dépasserait 300 millions d'années.

Deux familles de solutions s'opposent alors. Les méthodes *filtres* classent chaque variable selon un critère statistique ; elles sont rapides, mais évaluent les variables une à une, sans tenir compte de leurs interactions [1], [2]. Les méthodes *wrapper* prennent en compte ces interactions et obtiennent en général une meilleure précision, au prix d'un coût de calcul élevé [2], [7]. Les métaheuristiques comme l'AG et le BPSO appartiennent à cette seconde famille : elles exigent elles-mêmes beaucoup de ressources [2], [9], et, d'après le théorème *No Free Lunch*, aucune n'est garantie d'être la meilleure sur tous les problèmes [7]. Les comparaisons directes entre AG et BPSO rapportent d'ailleurs un avantage du BPSO, mais chacune sur un seul jeu de données et avec un classifieur différent [10], [11], ce qui ne permet pas de généraliser. Enfin, de nombreux travaux souffrent d'un biais de sélection, lorsque les données de test interviennent dans le choix des variables [2], [12] ; une comparaison fiable doit donc l'éviter.

Question de recherche et hypothèses

Cela nous amène à la question de recherche de ce projet :

Dans le cadre d'un problème de classification, l'utilisation d'un algorithme génétique pour sélectionner les variables justifie-t-elle son coût de calcul par rapport au PSO binaire et à une méthode filtre simple ?

Plus précisément, l'étude cherche à répondre aux questions suivantes :

Q1 À budget d'évaluations égal, l'AG obtient-il une meilleure précision de classification, moins de variables ou un temps de calcul plus court que le BPSO ?

Q2 L'AG et le BPSO apportent-ils une amélioration statistiquement significative par rapport à un filtre simple (test ANOVA F), nettement plus rapide à exécuter ?

Hypothèses, formulées *avant* les expériences :

H1 (Q2) AG et BPSO atteignent une précision au moins comparable à celle de la référence utilisant toutes les variables, avec nettement moins de variables.

H2 (Q2) L'avantage des métaheuristiques sur le filtre est plus marqué sur le jeu de données de plus grande dimension (Sonar, $N = 60$), où les interactions entre variables sont plus nombreuses.

H3 (question principale) Le temps de sélection des métaheuristiques dépasse celui du filtre d'au moins un ordre de grandeur.

H4 (Q1) Conformément aux comparaisons publiées [10], [11], le BPSO obtient une précision au moins égale à celle de l'AG ; nous testons si cet avantage se confirme à budget égal et sur plusieurs jeux de données.

Objectifs

1. Implémenter un AG et un BPSO pour la sélection de variables, avec la même fonction objectif et le même budget d'évaluations.
2. Les comparer à deux références simples selon trois critères mesurables : précision sur l'ensemble de test, nombre de variables retenues et temps de calcul.
3. Tester la significativité statistique des différences observées.

Démarche adoptée

La démarche est *quantitative et expérimentale* : la question porte sur des performances mesurables, et les hypothèses sont testées par des expériences répétées suivies d'un test statistique. Ce travail ne propose pas un nouvel algorithme ; sa contribution est une comparaison *contrôlée* : budget identique, référence filtre réglée de façon équitable, protocole sans fuite de l'ensemble de test, et code entièrement reproductible.

Organisation du rapport

Le chapitre 1 présente la méthodologie de recherche documentaire suivie et l'état de l'art. Le chapitre 2 décrit les jeux de données, la formulation du problème, les méthodes comparées et le protocole expérimental. Le chapitre 3 présente puis discute les résultats. Une conclusion générale résume les apports et propose des perspectives.

Chapitre 1

État de l'art

1.1 Introduction du chapitre

Ce chapitre a pour objectif de situer le projet dans la littérature. Il décrit d'abord la démarche de recherche documentaire suivie, puis présente les familles de méthodes de sélection de variables, les deux métaheuristiques étudiées et une synthèse critique des travaux existants, qui conduit au positionnement du projet.

1.2 Méthodologie de la recherche documentaire

1.2.1 De la question de recherche aux mots-clés

La question de recherche a été décomposée en quatre concepts, puis chaque concept a été traduit en anglais avec ses synonymes et acronymes (tableau 1.1).

Table 1.1 – Concepts de la question de recherche et mots-clés associés.

Concept	Mots-clés en anglais (synonymes, acronymes)
Sélection de variables	*feature selection*, *feature subset selection*, *variable selection*, *wrapper*
Algorithme génétique	*genetic algorithm*, *evolutionary algorithm*, *evolutionary computation*
PSO binaire	*particle swarm optimization*, PSO, BPSO, *binary PSO*, *transfer function*
Classification	*classification*, *classifier*, k-NN

1.2.2 Requête et bases interrogées

Les concepts ont été combinés avec les opérateurs booléens `OR` (synonymes d'un même concept) et `AND` (concepts différents) :

```
("feature selection" OR "feature subset selection" OR "variable selection")
AND ("genetic algorithm*" OR "particle swarm" OR BPSO)
AND classif*
```

La recherche a été menée sur Google Scholar, IEEE Xplore et ScienceDirect, avec deux filtres : période 2015–2026 pour les travaux récents (sans filtre de date pour les articles fondateurs), et documents de type article de revue ou de conférence en informatique. Les résultats ont été triés par nombre de citations pour repérer les travaux fondateurs et par date pour repérer les travaux récents.

TABLE 1.2 – Résultats de la recherche documentaire.

Base	Résultats bruts	Après filtres	Retenus après lecture
Google Scholar	17 600	17 400	20+
ScienceDirect	1 032	79	40
IEEE Xplore			

1.2.3 Critères de sélection et organisation

Un document a été retenu s'il (i) traite de la sélection de variables pour la classification, (ii) décrit sa méthode de façon reproductible, et (iii) provient d'une source identifiable : revue indexée, conférence avec comité de lecture ou ouvrage de référence. Les sources ont été combinées selon leur rôle : articles fondateurs, revues de synthèse et travaux récents. Les références ont été gérées avec Zotero et exportées au format BibTeX ; pour chaque article lu, une fiche de lecture (objectif, méthode, résultats, limites) a été remplie (annexe B).

1.3 Familles de méthodes de sélection de variables

On distingue classiquement trois familles de méthodes [1].

— Les méthodes **filtres** attribuent un score à chaque variable à l'aide d'un critère statistique (corrélation, test ANOVA F, information mutuelle), indépendamment de tout classifieur.

— Les méthodes **wrapper** évaluent chaque *sous-ensemble* candidat par la performance du classifieur lui-même [8]. Une méthode wrapper associe une *stratégie de recherche* dans l'espace des sous-ensembles à une *fonction d'évaluation*.

— Les méthodes **embarquées** réalisent la sélection pendant l'apprentissage du modèle, par exemple par régularisation L_1 (Lasso) ou par l'importance des variables dans les arbres de décision.

Le tableau 1.3 compare ces familles selon quatre critères explicites.

TABLE 1.3 – Comparaison des familles de méthodes de sélection de variables.

Critère	Filtre	Wrapper	Embarquée
Coût de calcul	faible	élevé	moyen
Prise en compte des interactions	non (univarié)	oui	partielle
Dépendance au classifieur	non	oui	oui (modèle imposé)
Risque de sur-apprentissage de la sélection	faible	élevé	moyen

Ce projet compare deux *stratégies de recherche* wrapper (AG et BPSO) avec la même fonction d'évaluation, et les confronte à un filtre.

1.4 Algorithmes génétiques pour la sélection de variables

Les algorithmes génétiques, introduits par Holland [3] et popularisés par Goldberg [13], imitent l'évolution naturelle : une population de solutions évolue par sélection des meilleurs individus, croisement et mutation. Le codage binaire, où chaque gène indique la présence ou l'absence d'une variable, rend l'AG naturellement adapté à la sélection de variables. Yang et Honavar [4] ont été parmi les premiers à l'appliquer à ce problème, avec une fonction objectif combinant la précision d'un réseau de neurones et le coût des variables retenues.

1.5 PSO et sa version binaire

L'optimisation par essaim particulaire (PSO) a été proposée par Kennedy et Eberhart [14], en s'inspirant du déplacement collectif des vols d'oiseaux. Chaque particule se déplace en combinant sa vitesse précédente, l'attraction vers sa meilleure position passée et l'attraction vers la meilleure position de l'essaim. La version d'origine opère dans un espace continu. Les mêmes auteurs ont proposé une version binaire (BPSO) [5] : la vitesse reste réelle, mais elle est transformée par une fonction sigmoïde en *probabilité* que le bit correspondant vaille 1. Mirjalili et Lewis [15] ont montré que le choix de cette fonction de transfert (en forme de S ou de V) influence fortement les performances du BPSO.

1.6 Synthèse critique et positionnement

Les revues de synthèse [2], [6], [7] montrent que les métaheuristiques, et en particulier l'AG et le PSO, occupent une place centrale dans la littérature sur la sélection de variables, avec un nombre de variantes en forte croissance. Xue et al. [2] soulignent aussi que le coût de calcul des approches wrapper et la rigueur du protocole d'évaluation restent des points délicats. Le tableau 1.4 résume les travaux sur lesquels s'appuie ce projet.

Table 1.4 – Synthèse de travaux représentatifs.

Référence	Méthode	Évaluation	Limite relevée
Kohavi et John [8]	Wrapper, recherche heuristique (hill-climbing, best-first)	Arbre ID3, Naïve Bayes	Coût de calcul élevé
Yang et Honavar [4]	AG à codage binaire, fitness précision + coût	Réseau de neurones	Résultats liés au classifieur choisi
Kennedy et Eberhart [5]	Introduction du BPSO (fonction sigmoïde)	Fonctions de test	Pas d'application à la sélection de variables
Mirjalili et Lewis [15]	BPSO, fonctions de transfert en S et en V	Fonctions de test	Pas d'application à la sélection de variables
Babaoğlu et al. [10]	BPSO vs AG en mode wrapper, 23 variables	SVM, CV k plis ; 1 jeu médical	Un seul jeu de données
Rafdi et al. [11]	PSO vs AG pour l'analyse de sentiments	Naïve Bayes ; 1 jeu Twitter	Un seul jeu ; paramètres non précisés dans le résumé
Ludwig [9]	BPSO guidé, initialisé par des filtres ; comparé à BPSO, AG, ANOVA	k-NN ; 12 jeux génomiques ($> 35\,000$ variables)	Coût de calcul élevé (signalé par l'auteur)

Les comparaisons directes entre AG et BPSO rapportent un avantage du BPSO : Babaoğlu et al. [10] l'observent pour le diagnostic de la maladie coronarienne avec un SVM, et Rafdi et al. [11] pour l'analyse de sentiments avec un classifieur bayésien naïf. Ces deux études portent toutefois chacune sur un seul jeu de données. Sur des données génomiques de très grande dimension, Ludwig [9] compare un BPSO amélioré à plusieurs méthodes, dont l'AG, le BPSO standard et un filtre ANOVA, et observe des résultats de précision partagés entre les variantes de PSO, avec un temps d'exécution élevé.

La lacune visée par ce projet n'est pas algorithmique mais méthodologique. Les comparaisons AG/BPSO disponibles reposent sur un seul jeu de données [10], [11] ou sur des données d'une dimension très éloignée des jeux usuels [9]. Ce projet compare l'AG et le BPSO sur plusieurs jeux de dimension moyenne, à budget égal, sans fuite de l'ensemble de test, et face à un filtre simple, afin de mesurer ce que la complexité des métaheuristiques apporte réellement.

1.7 Conclusion du chapitre

L'état de l'art établit trois points : la sélection de variables est un problème combinatoire pour lequel les métaheuristiques wrapper sont très utilisées ; l'AG et le BPSO reposent sur un codage binaire directement adapté au problème ; leur coût et la rigueur de leur évaluation restent discutés. Le chapitre suivant décrit le dispositif expérimental conçu pour répondre à la question de recherche.

Chapitre 2

Matériels et méthodologie

2.1 Introduction du chapitre

Ce chapitre décrit précisément comment les résultats ont été obtenus, afin qu'un autre chercheur puisse les reproduire : jeux de données, formulation du problème, méthodes comparées, protocole expérimental, critères d'évaluation et environnement logiciel.

2.2 Jeux de données

Trois jeux de données de référence, à deux classes, sont utilisés (tableau 2.1). Ils sont publics et couramment employés dans la littérature sur la sélection de variables, ce qui rend l'expérience reproductible.

TABLE 2.1 – Jeux de données utilisés (source : UCI Machine Learning Repository [16]).

Jeu de données	n (exemples)	N (variables)	Tâche
Breast Cancer Wisconsin	569	30	tumeur bénigne / maligne
Sonar	208	60	signal sonar : mine / roche
Ionosphere	351	34	signal radar : bon / mauvais

2.3 Formulation du problème

Une solution est un vecteur binaire

$$\mathbf{x} = (x_1, \ldots, x_N) \in \{0,1\}^N,$$

où $x_j = 1$ signifie que la variable j est sélectionnée. On note $S = \{\, j : x_j = 1 \,\}$ et $|S|$ le nombre de variables retenues. La fonction objectif, à **minimiser**, est :

$$f(\mathbf{x}) = \alpha \,(1 - \mathrm{Acc}_{\mathrm{CV}}(S)) + (1-\alpha)\,\frac{|S|}{N}, \tag{2.1}$$

où $\mathrm{Acc}_{\mathrm{CV}}(S)$ est la précision moyenne d'un k-NN ($k = 5$) en validation croisée à 5 plis **sur l'ensemble d'apprentissage uniquement**, et $\alpha = 0{,}99$. Si $|S| = 0$, on pose $f(\mathbf{x}) = 1$.

Cette formulation, qui combine l'erreur de classification et la proportion de variables retenues, est courante dans la littérature ; Ludwig [9] l'utilise également avec un classifieur k-NN. Le paramètre α fixe la priorité entre les deux objectifs. Avec $\alpha = 0{,}99$, la précision domine : le terme $|S|/N$ sert surtout à départager deux sous-ensembles de précision voisine, en favorisant le plus petit. Avec $\alpha = 1$, seule la précision compterait ; avec $\alpha = 0{,}5$, réduire le nombre de variables pèserait autant que réduire l'erreur.

2.4 Méthodes comparées

2.4.1 Références simples

— **Toutes** : toutes les variables sont utilisées, sans sélection.
— **Filtre** : les variables sont classées par le score du test ANOVA F, puis les k meilleures sont conservées ; k est choisi par validation croisée sur l'apprentissage parmi 10 %, 20 %, 30 %, 50 % et 75 % de N.

2.4.2 Algorithme génétique (AG)

Chaque individu est un vecteur binaire de longueur N, initialisé en tirant chaque bit à 1 avec une probabilité de 0,5. À chaque génération, les parents sont choisis par *tournoi* de taille 3 : trois individus sont tirés au hasard et le meilleur est retenu. Deux parents produisent deux enfants par *croisement uniforme* (probabilité $p_c = 0{,}9$) : chaque gène est hérité de l'un ou l'autre parent avec une probabilité de 1/2. Chaque gène des enfants est ensuite inversé avec une probabilité $p_m = 1/N$, soit en moyenne une mutation par individu. Enfin, l'*élitisme* copie le meilleur individu tel quel dans la génération suivante, ce qui garantit que la meilleure fitness ne se dégrade jamais (algorithme 1).

Algorithme 1 Algorithme génétique pour la sélection de variables

Entrée : taille de population P, générations T, probabilités p_c, p_m
Sortie : meilleur masque $\mathbf{x}^\star$

Initialiser P vecteurs binaires aléatoires ; évaluer f ; mémoriser le meilleur $\mathbf{x}^\star$
for $t = 1$ **à** T **do**
  Nouvelle population $\leftarrow \{\mathbf{x}^\star\}$ ▷ élitisme
  while la nouvelle population compte moins de P individus **do**
    Choisir deux parents par tournoi de taille 3
    Avec probabilité p_c, appliquer le croisement uniforme
    Inverser chaque bit des enfants avec probabilité p_m ; ajouter les enfants
  end while
  Évaluer f ; mettre à jour $\mathbf{x}^\star$
end for
return $\mathbf{x}^\star$

2.4.3 PSO binaire (BPSO)

Pour chaque particule i et chaque dimension d, la vitesse est mise à jour par :

$$v_{id}^{t+1} = w\, v_{id}^{t} + c_1 r_1 (p_{id} - x_{id}^{t}) + c_2 r_2 (g_d - x_{id}^{t}), \tag{2.2}$$

puis la nouvelle position est tirée à l'aide de la fonction de transfert sigmoïde :

$$S(v) = \frac{1}{1 + e^{-v}}, \qquad x_{id}^{t+1} = \begin{cases} 1 & \text{si } r < S(v_{id}^{t+1}), \\ 0 & \text{sinon,} \end{cases} \tag{2.3}$$

avec $r_1, r_2, r \sim \mathcal{U}(0,1)$, $\mathbf{p}_i$ la meilleure position passée de la particule i, $\mathbf{g}$ la meilleure position de l'essaim, et $v \in [-v_{\max}, v_{\max}]$.

Dans l'équation (2.2), le terme $w\, v_{id}^{t}$ (*inertie*) conserve une partie du mouvement précédent ; le terme *cognitif* $c_1 r_1 (p_{id} - x_{id}^{t})$ attire la particule vers sa propre meilleure solution ; le terme *social* $c_2 r_2 (g_d - x_{id}^{t})$ l'attire vers la meilleure solution de l'essaim. Une vitesse fortement positive rend la valeur 1 très probable, une vitesse fortement négative rend la valeur 0 très probable. L'inertie w décroît linéairement de 0,9 à 0,4 : l'essaim explore largement au début, puis se

concentre autour des meilleures solutions. Le bornage $v_{\max} = 6$ limite l'amplitude des vitesses (algorithme 2).

Algorithme 2 PSO binaire pour la sélection de variables

Entrée : particules P, itérations T, $w_{\max}$, $w_{\min}$, c_1, c_2, $v_{\max}$
Sortie : meilleur masque $\mathbf{g}$

Initialiser positions binaires et vitesses ; évaluer f ; initialiser $\mathbf{p}_i$ et $\mathbf{g}$
for $t = 1$ **à** T **do**
    $w \leftarrow w_{\max} - (w_{\max} - w_{\min})\,(t-1)/(T-1)$
    for chaque particule i **do**
        Mettre à jour la vitesse (éq. 2.2) et la borner dans $[-v_{\max}, v_{\max}]$
        Tirer la nouvelle position (éq. 2.3)
        Évaluer f ; mettre à jour $\mathbf{p}_i$ si la solution est meilleure
    end for
    Mettre à jour $\mathbf{g}$
end for
return $\mathbf{g}$

2.4.4 Équité de la comparaison

AG et BPSO disposent du **même budget** : $P = 20$ individus et $T = 30$ itérations, soit $20 + 20 \times 30 = 620$ évaluations de f par exécution (tableau 2.2). Au sein d'une même répétition, ils utilisent les mêmes plis de validation croisée, donc exactement la même fonction objectif. Un masque déjà évalué est mémorisé et n'est pas réentraîné, ce qui accélère le calcul sans modifier le budget compté.

Table 2.2 – Paramètres des métaheuristiques.

Paramètre	AG	BPSO
Taille de population	20	20
Itérations	30	30
Spécifiques	tournoi $= 3$, $p_c = 0{,}9$, $p_m = 1/N$	$w : 0{,}9 \to 0{,}4$, $c_1 = c_2 = 2$, $v_{\max} = 6$

2.5 Protocole expérimental

Pour chaque répétition $r = 0, \ldots, R-1$ (avec $R = 10$) :

1. découpage stratifié 70 % apprentissage / 30 % test (graine r) ;
2. standardisation ajustée sur l'apprentissage seulement ;
3. sélection des variables par chaque méthode, **sur l'apprentissage seulement** ;
4. entraînement d'un k-NN ($k = 5$) sur les variables retenues et mesure sur le test.

Les quatre méthodes partagent le même découpage à chaque répétition. La sélection n'utilise jamais l'ensemble de test, afin d'éviter le biais de sélection décrit par Ambroise et McLachlan [12], qui rend les performances artificiellement optimistes.

2.6 Critères d'évaluation et analyse statistique

Trois mesures sont relevées pour chaque méthode : la précision sur l'ensemble de test, le nombre de variables sélectionnées $|S|$ et le temps de sélection en secondes. Elles sont résumées par la moyenne et l'écart-type sur les R répétitions.

Comme les méthodes partagent le même découpage, les mesures sont *appariées*. Les différences sont donc testées par le test des rangs signés de Wilcoxon, bilatéral, au seuil de 0,05 [17]. Ce test non paramétrique ne suppose pas la normalité des différences, ce qui convient à un petit nombre de répétitions.

2.7 Environnement logiciel et reproductibilité

Les expériences ont été réalisées sous Python 3.13.16 avec NumPy 2.1.3 et scikit-learn 1.6.1 (Google Colab, processeur x86_64, 2 cœurs). La durée totale des expériences est d'environ 11 min.L'implémentation repose sur scikit-learn [18]. Toutes les graines aléatoires sont fixées, et le code complet est fourni (annexe A).

2.8 Conclusion du chapitre

Le dispositif décrit garantit trois conditions : une fonction objectif et un budget identiques pour l'AG et le BPSO, une sélection réalisée sans accès à l'ensemble de test, et des mesures appariées permettant un test statistique. Le chapitre suivant présente les résultats obtenus dans ces conditions.

Chapitre 3

Résultats et discussion

3.1 Introduction du chapitre

Ce chapitre présente les résultats dans l'ordre des objectifs annoncés (précision, nombre de variables, temps de calcul, significativité), puis les interprète au regard des hypothèses et de la littérature.

3.2 Précision de classification

TABLE 3.1 – Précision sur le test en % (moyenne ± écart-type sur $R = 10$ répétitions). Meilleure moyenne en gras.

Jeu de données	Toutes	Filtre	AG	BPSO
Breast Cancer	**96,3 ± 1,4**	96,0 ± 1,6	96,0 ± 1,8	96,0 ± 1,3
Sonar	80,0 ± 4,6	77,6 ± 5,4	**81,3 ± 6,4**	79,4 ± 5,3
Ionosphere	83,3 ± 2,1	86,8 ± 5,0	**88,0 ± 3,6**	87,0 ± 2,6

Sur Breast Cancer, la meilleure précision moyenne est obtenue par la référence Toutes (96,3 %). Par rapport à l'utilisation de toutes les variables (96,3 %), l'écart est de −0,4 point pour l'AG, −0,3 point pour le BPSO et −0,4 point pour le filtre. Sur Sonar, la meilleure précision moyenne est obtenue par l'AG (81,3 %). Par rapport à l'utilisation de toutes les variables (80,0 %), l'écart est de +1,3 point pour l'AG, −0,6 point pour le BPSO et −2,4 points pour le filtre. Sur Ionosphere, la meilleure précision moyenne est obtenue par l'AG (88,0 %). Par rapport à l'utilisation de toutes les variables (83,3 %), l'écart est de +4,7 points pour l'AG, +3,7 points pour le BPSO et +3,5 points pour le filtre. Les écarts-types de la précision varient de 1,3 à 6,4 points selon la méthode et le jeu de données (tableau 3.1, figure 3.1).

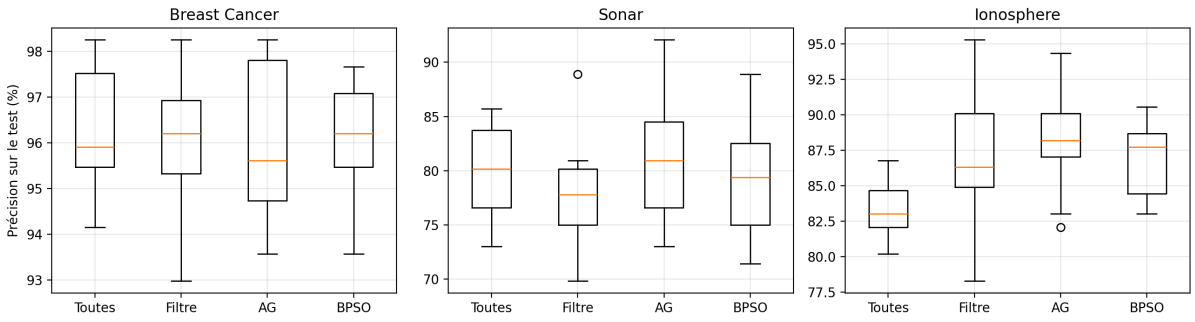


FIGURE 3.1 – Distribution de la précision sur le test sur les 10 répétitions.

3.3 Nombre de variables sélectionnées

TABLE 3.2 – Nombre de variables sélectionnées $|S|$ (moyenne ± écart-type). Plus petite moyenne en gras (hors Toutes).

Jeu de données	Toutes	Filtre	AG	BPSO
Breast Cancer	30	$22{,}0 \pm 0{,}0$	$\mathbf{13{,}3 \pm 3{,}2}$	$14{,}3 \pm 1{,}9$
Sonar	60	$29{,}4 \pm 11{,}0$	$\mathbf{25{,}9 \pm 3{,}8}$	$28{,}5 \pm 4{,}0$
Ionosphere	34	$\mathbf{6{,}8 \pm 6{,}8}$	$7{,}8 \pm 1{,}2$	$9{,}5 \pm 2{,}1$

Sur Breast Cancer ($N = 30$), l'AG retient en moyenne 13,3 variables (44 % de N), le BPSO 14,3 (48 %) et le filtre 22,0 (73 %). Sur Sonar ($N = 60$), l'AG retient en moyenne 25,9 variables (43 % de N), le BPSO 28,5 (48 %) et le filtre 29,4 (49 %). Sur Ionosphere ($N = 34$), l'AG retient en moyenne 7,8 variables (23 % de N), le BPSO 9,5 (28 %) et le filtre 6,8 (20 %). L'écart-type moyen de $|S|$ entre répétitions est de 2,7 pour l'AG, 2,7 pour le BPSO et 5,9 pour le filtre (tableau 3.2).

3.4 Temps de calcul

TABLE 3.3 – Temps moyen de sélection par exécution (secondes) et rapport au temps du filtre.

Jeu de données	Filtre	AG	BPSO	AG / Filtre	BPSO / Filtre
Breast Cancer	0,18	10,33	13,98	×57	×78
Sonar	0,16	7,09	9,18	×44	×58
Ionosphere	0,17	9,66	12,29	×56	×72

Le filtre sélectionne les variables en 0,16 à 0,18 s selon le jeu de données. La sélection par AG est 44 à 57 fois plus lente, et celle par BPSO 58 à 78 fois plus lente (tableau 3.3). À budget égal, le BPSO est plus lent que l'AG sur les trois jeux de données. Le nombre d'évaluations étant identique, cet écart provient surtout du nombre de sous-ensembles distincts réellement évalués (la mémoïsation évite de réentraîner un masque déjà vu) et de la taille des sous-ensembles évalués.

3.5 Significativité statistique

TABLE 3.4 – Test de Wilcoxon apparié, bilatéral (valeurs p ; en gras si $p < 0{,}05$).

	AG vs BPSO		AG vs Filtre	BPSO vs Filtre	AG vs Toutes	BPSO vs Toutes
Jeu de données	précision	$\lvert S\rvert$	précision	précision	précision	précision
Breast Cancer	0,863	0,467	1,000	1,000	0,266	0,477
Sonar	0,416	0,160	0,258	0,242	0,523	0,438
Ionosphere	0,391	**0,008**	0,586	1,000	**0,004**	**0,004**

Sur Breast Cancer, la différence de précision entre AG et BPSO n'est pas significative ($p = 0{,}863$), et celle du nombre de variables n'est pas significative ($p = 0{,}467$). Par rapport au filtre, la différence de précision de l'AG n'est pas significative ($p = 1{,}000$) ; celle du BPSO n'est pas significative ($p = 1{,}000$). Sur Sonar, la différence de précision entre AG et BPSO n'est pas significative ($p = 0{,}416$), et celle du nombre de variables n'est pas significative ($p = 0{,}160$). Par

rapport au filtre, la différence de précision de l'AG n'est pas significative ($p = 0{,}258$) ; celle du BPSO n'est pas significative ($p = 0{,}242$). Sur Ionosphere, la différence de précision entre AG et BPSO n'est pas significative ($p = 0{,}391$), et celle du nombre de variables est significative ($p = 0{,}008$). Par rapport au filtre, la différence de précision de l'AG n'est pas significative ($p = 0{,}586$) ; celle du BPSO n'est pas significative ($p = 1{,}000$). Avec $R = 10$ répétitions, la plus petite valeur p atteignable par le test de Wilcoxon bilatéral exact est d'environ 0,002 (tableau 3.4).

3.6 Convergence des métaheuristiques

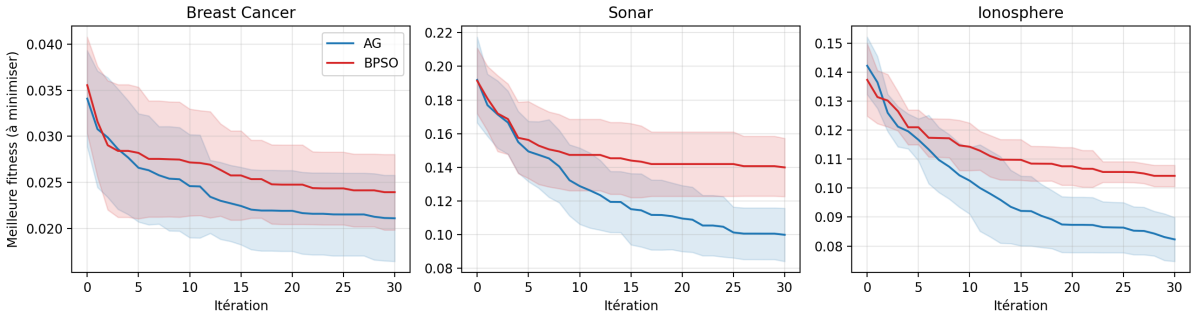


FIGURE 3.2 – Convergence : meilleure fitness moyenne par itération (± écart-type, 10 répétitions).

Sur Breast Cancer, l'AG atteint la meilleure fitness moyenne finale (AG : 0,0211 ; BPSO : 0,0239). L'AG réalise 95 % de son amélioration totale à l'itération 21, le BPSO à l'itération 22. Sur Sonar, l'AG atteint la meilleure fitness moyenne finale (AG : 0,0999 ; BPSO : 0,1399). L'AG réalise 95 % de son amélioration totale à l'itération 25, le BPSO à l'itération 17. Sur Ionosphere, l'AG atteint la meilleure fitness moyenne finale (AG : 0,0823 ; BPSO : 0,1042). L'AG réalise 95 % de son amélioration totale à l'itération 27, le BPSO à l'itération 23. La courbe moyenne de l'AG décroît encore au cours des cinq dernières itérations sur Breast Cancer, Sonar et Ionosphere, ce qui suggère qu'un budget plus élevé pourrait encore l'améliorer. La courbe moyenne du BPSO décroît encore au cours des cinq dernières itérations sur Breast Cancer, Sonar et Ionosphere, ce qui suggère qu'un budget plus élevé pourrait encore l'améliorer. (Figure 3.2.)

3.7 Discussion

3.7.1 Vérification des hypothèses

H1 est confirmée sur les trois jeux de données. Critère : sur un jeu de données, H1 est vérifiée si la précision de l'AG et du BPSO n'est pas significativement inférieure à celle de la référence Toutes et si chacun retient au plus la moitié des variables (tableaux 3.1, 3.2 et 3.4).

H2 est confirmée. L'écart de précision entre la meilleure métaheuristique et le filtre vaut +0,1 point sur Breast Cancer, +3,7 points sur Sonar, +1,2 point sur Ionosphere ; il est le plus grand sur Sonar, qui est bien le jeu de plus grande dimension ($N = 60$).

H3 est confirmée. Le plus petit rapport de temps observé entre une métaheuristique et le filtre est de 44 (tableau 3.3) ; le seuil d'un ordre de grandeur correspond à un rapport de 10.

H4 est confirmée au sens faible : le BPSO n'est significativement moins précis que l'AG sur aucun jeu de données (sa précision moyenne est supérieure ou égale sur 1 des 3 jeux), mais aucune différence n'est significative.

3.7.2 Interprétation

Filtre et interactions entre variables. Le filtre ANOVA évalue chaque variable isolément [1]. Lorsqu'il obtient une précision comparable à celle des métaheuristiques, cela indique que, sur ces jeux de données, les variables utiles le sont déjà individuellement : la prise en compte des interactions, qui est l'avantage théorique des approches wrapper [2], [8], n'apporte alors qu'un gain limité. À l'inverse, un avantage significatif d'une métaheuristique signale des variables utiles seulement en combinaison.

Sur-apprentissage du critère de sélection. Sur l'ensemble des répétitions, pour l'AG, la précision estimée en validation croisée sur l'apprentissage dépasse la précision mesurée sur le test de 5,1 points en moyenne ; pour le BPSO, la précision estimée en validation croisée sur l'apprentissage dépasse la précision mesurée sur le test de 3,9 points en moyenne. Cet écart positif montre que la fitness optimisée est une estimation optimiste : à force d'évaluer des centaines de sous-ensembles sur les mêmes plis, la recherche finit par exploiter des particularités de l'ensemble d'apprentissage. C'est précisément pour mesurer ce phénomène que la précision est rapportée sur un ensemble de test jamais utilisé pendant la sélection [8], [12].

Nombre de variables et rôle de α. Avec $\alpha = 0{,}99$, la fonction objectif (2.1) privilégie fortement la précision : réduire le nombre de variables ne rapporte qu'un gain très faible. Les métaheuristiques n'ont donc pas de raison forte de produire des sous-ensembles plus petits que le filtre, dont la taille k est choisie par validation croisée. Un poids α plus faible conduirait à des sous-ensembles plus compacts, au prix d'une précision éventuellement moindre.

Variabilité des solutions. L'AG et le BPSO sont des algorithmes stochastiques : d'une graine à l'autre, ils peuvent produire des sous-ensembles différents [2]. Les écarts-types de $|S|$ rapportés dans le tableau 3.2 mesurent cette instabilité, alors que le filtre, déterministe pour un découpage donné, ne varie qu'avec les données d'apprentissage.

3.7.3 Comparaison avec la littérature

Babaoğlu et al. [10] et Rafdi et al. [11] rapportent un avantage du BPSO sur l'AG, chacun sur un seul jeu de données. Nos résultats nuancent cette tendance : à budget égal et sur trois jeux de données, aucune différence de précision entre AG et BPSO n'est statistiquement significative. L'avantage rapporté dans ces études, obtenu sur un seul jeu de données, ne se généralise donc pas ici. Ces comparaisons restent qualitatives : les études citées utilisent d'autres jeux de données, d'autres classifieurs (SVM, Naïve Bayes) et ne précisent pas toujours le budget d'évaluations, ce qui empêche de comparer directement les valeurs de précision. Ludwig [9], qui emploie comme ici un k-NN et un filtre ANOVA, observe également un coût de calcul élevé des variantes de PSO ; nos mesures de temps (tableau 3.3) vont dans ce sens à plus petite échelle.

3.7.4 Limites

Ces conclusions restent limitées par plusieurs choix. Seules $R = 10$ répétitions ont été réalisées, ce qui réduit la puissance du test statistique. Un seul classifieur (k-NN) a été utilisé : les sous-ensembles sélectionnés pourraient ne pas convenir à un autre modèle. Les paramètres des métaheuristiques n'ont pas été optimisés, et un budget plus élevé aurait pu modifier le classement. Enfin, trois jeux de données de dimension moyenne ne permettent pas de généraliser à des données de grande dimension (plusieurs milliers de variables).

3.8 Conclusion du chapitre

Les résultats établissent les points suivants : H1 est confirmée, H2 est confirmée, H3 est confirmée et H4 est confirmée au sens faible. Dans nos conditions expérimentales, l'AG n'améliore significativement la précision du filtre sur aucun jeu de données, alors que sa sélection est 44 à 57 fois plus lente : du point de vue de la précision, son coût de calcul n'est pas justifié.

Conclusion générale et perspectives

Ce projet avait pour objectif de déterminer si deux métaheuristiques, l'AG et le BPSO, apportent un gain mesurable par rapport à une méthode filtre simple pour la sélection de variables, à budget égal et selon un protocole sans fuite de l'ensemble de test.

Pour y répondre, un AG et un BPSO ont été implémentés avec la même fonction objectif et le même budget, puis comparés à l'utilisation de toutes les variables et à un filtre ANOVA, sur trois jeux de données et dix répétitions appariées. Dans nos conditions expérimentales, l'AG n'améliore significativement la précision du filtre sur aucun jeu de données, alors que sa sélection est 44 à 57 fois plus lente : du point de vue de la précision, son coût de calcul n'est pas justifié.

Ce résultat rejoint une idée centrale de la méthodologie expérimentale : une méthode complexe doit toujours être comparée à une référence simple, réglée avec le même soin, avant de conclure à son intérêt.

La contribution de ce travail est méthodologique : un protocole de comparaison équitable et entièrement reproductible, réutilisable pour évaluer d'autres méthodes de sélection.

Plusieurs prolongements découlent de ces résultats : tester des fonctions de transfert en V pour le BPSO [15], évaluer les sous-ensembles avec d'autres classifieurs, étendre l'étude à des jeux de données de plus grande dimension, et traiter la précision et le nombre de variables comme deux objectifs distincts dans une approche multi-objectif.

Références

[1] I. Guyon et A. Elisseeff, « An Introduction to Variable and Feature Selection, » *Journal of Machine Learning Research*, t. 3, p. 1157-1182, 2003. adresse : https://www.jmlr.org/papers/v3/guyon03a.html

[2] B. Xue, M. Zhang, W. N. Browne et X. Yao, « A Survey on Evolutionary Computation Approaches to Feature Selection, » *IEEE Transactions on Evolutionary Computation*, t. 20, n° 4, p. 606-626, 2016. doi : 10.1109/TEVC.2015.2504420

[3] J. H. Holland, *Adaptation in Natural and Artificial Systems*. Ann Arbor : University of Michigan Press, 1975.

[4] J. Yang et V. Honavar, « Feature Subset Selection Using a Genetic Algorithm, » *IEEE Intelligent Systems and their Applications*, t. 13, n° 2, p. 44-48, 1998. doi : 10.1109/5254.671091

[5] J. Kennedy et R. C. Eberhart, « A Discrete Binary Version of the Particle Swarm Algorithm, » in *Proceedings of the IEEE International Conference on Systems, Man, and Cybernetics*, t. 5, 1997, p. 4104-4108. doi : 10.1109/ICSMC.1997.637339

[6] P. Agrawal, H. F. Abutarboush, T. Ganesh et A. W. Mohamed, « Metaheuristic Algorithms on Feature Selection : A Survey of One Decade of Research (2009–2019), » *IEEE Access*, t. 9, p. 26 766-26 791, 2021. doi : 10.1109/ACCESS.2021.3056407

[7] T. Dokeroglu, A. Deniz et H. E. Kiziloz, « A Comprehensive Survey on Recent Metaheuristics for Feature Selection, » *Neurocomputing*, t. 494, p. 269-296, 2022. doi : 10.1016/j.neucom.2022.04.083

[8] R. Kohavi et G. H. John, « Wrappers for Feature Subset Selection, » *Artificial Intelligence*, t. 97, n° 1–2, p. 273-324, 1997. doi : 10.1016/S0004-3702(97)00043-X

[9] S. A. Ludwig, « Guided Particle Swarm Optimization for Feature Selection : Application to Cancer Genome Data, » *Algorithms*, t. 18, n° 4, p. 220, 2025. doi : 10.3390/a18040220

[10] İ. Babaoğlu, O. Findik et E. Ülker, « A Comparison of Feature Selection Models Utilizing Binary Particle Swarm Optimization and Genetic Algorithm in Determining Coronary Artery Disease Using Support Vector Machine, » *Expert Systems with Applications*, t. 37, n° 4, p. 3177-3183, 2010. doi : 10.1016/j.eswa.2009.09.064

[11] A. Rafdi, H. Mawengkang et S. Efendi, « Sentiment Analysis Using Naive Bayes Algorithm with Feature Selection Particle Swarm Optimization (PSO) and Genetic Algorithm, » *International Journal of Advances in Data and Information Systems*, t. 2, n° 2, p. 96-104, 2021. doi : 10.25008/ijadis.v2i2.1224

[12] C. Ambroise et G. J. McLachlan, « Selection Bias in Gene Extraction on the Basis of Microarray Gene-Expression Data, » *Proceedings of the National Academy of Sciences*, t. 99, n° 10, p. 6562-6566, 2002. doi : 10.1073/pnas.102102699

[13] D. E. Goldberg, *Genetic Algorithms in Search, Optimization and Machine Learning*. Reading, MA : Addison-Wesley, 1989.

[14] J. Kennedy et R. Eberhart, « Particle Swarm Optimization, » in *Proceedings of the IEEE International Conference on Neural Networks (ICNN'95)*, t. 4, 1995, p. 1942-1948. doi : 10.1109/ICNN.1995.488968

[15] S. Mirjalili et A. Lewis, « S-shaped versus V-shaped Transfer Functions for Binary Particle Swarm Optimization, » *Swarm and Evolutionary Computation*, t. 9, p. 1-14, 2013. doi : 10.1016/j.swevo.2012.09.002

[16] M. Kelly, R. Longjohn et K. Nottingham, *The UCI Machine Learning Repository*, https://archive.ics.uci.edu, Consulté le 24 octobre 2026.

[17] J. Demšar, « Statistical Comparisons of Classifiers over Multiple Data Sets, » *Journal of Machine Learning Research*, t. 7, p. 1-30, 2006. adresse : https://www.jmlr.org/papers/v7/demsar06a.html

[18] F. Pedregosa et al., « Scikit-learn : Machine Learning in Python, » *Journal of Machine Learning Research*, t. 12, p. 2825-2830, 2011. adresse : https://www.jmlr.org/papers/v12/pedregosa11a.html

Annexe A

Code source et reproductibilité

Toutes les expériences sont reproductibles à partir du notebook `projet_selection_variables.ipynb` (Google Colab), qui fixe toutes les graines aléatoires et génère automatiquement les tableaux et figures du chapitre 3. Le code complet, les résultats bruts et les figures sont disponibles dans le dépôt GitHub du projet : `https://github.com/hamzaoukha/S-lection-de-variables-pour-la-classification-par-Algorithme-G-n-tique`. Le notebook peut être exécuté directement dans Google Colab.. Il produit également les fichiers de résultats bruts (`resultats_bruts.csv`), le résumé statistique (`resume.csv`) et les valeurs p (`wilcoxon.csv`), ainsi que le fichier `resultats_auto.tex` inséré dans le chapitre 3.

Annexe B

Fiches de lecture

Table B.1 – Fiches de lecture des principaux articles.

Référence	Objectif	Méthode	Résultats	Limites
Xue et al. [2]	Revue des approches évolutionnaires pour la sélection de variables	Synthèse par algorithme (AG, PSO, etc.) et par type d'évaluation (filtre, wrapper)	Approches largement utilisées pour leur capacité de recherche globale	Défis : coût de calcul, passage à l'échelle, stabilité, biais de sélection
Mirjalili et Lewis [15]	Étudier la fonction de transfert du BPSO	Comparaison de fonctions en S et en V sur des fonctions de test	Les fonctions en V améliorent nettement le BPSO	Pas d'évaluation en sélection de variables
Dokeroglu et al. [7]	Revue des métaheuristiques récentes pour la sélection	Synthèse des travaux récents, classifieurs et réglages	Problème NP-difficile ; aucune métaheuristique universelle (No Free Lunch)	Réglage des paramètres et équilibre exploration/exploitation ouverts
Babaoğlu et al. [10]	Comparer BPSO et AG pour le diagnostic coronarien	SVM, validation croisée k plis, 23 variables	BPSO plus précis que l'AG et que toutes les variables	Un seul jeu de données
Rafdi et al. [11]	Améliorer un Naïve Bayes en analyse de sentiments	Sélection par PSO et par AG, validation croisée	Précision : 60,3 % sans sélection, 77,5 % (PSO), 70,7 % (AG)	Un seul jeu ; réglages non détaillés dans le résumé
Ludwig [9]	BPSO guidé, initialisé par des filtres	k-NN, 12 jeux génomiques, test de Mann–Whitney	Précision partagée avec le BPSO ; meilleur F1 sur plusieurs jeux	Coût de calcul élevé